Erschließungs- und Visualisierungswerkzeuge für den Imagekatalog der Musikabteilung der Staatsbibliothek zu Berlin

Zwischenbericht

Wer sind wir?11

Betreuer: Dr. David Zellhöfer

Beteiligten:

- Simon Albrecht
- Lars Görisch
- Jakob Schmolling

Staatsbibliothek zu Berlin

- 1661 Gegründet als "Churfürstliche Bibliothek zu Cölln an der Spree"
- Heute: Eine der größten Bibliotheken der Welt
- 11 Millionen Druckschriften
- 1,1 Millionen Karten, Atlanten, Globen
- 480.000 Handschriften und Autographen



Johann Sebastian Bach - Weihnachtsoratorium - 1734

Was ist ein Imagekatalog?

- Karteikartenkatalog seit dem 19. Jahrhundert
- Heute ersetzt durch Online-Kataloge (OPAC)
- Imagekatalog ist ein digitalisierter
 Karteikartenkatalog (Scans)
- eine Million Karteikarten
- Retrokonversion nötig



By Dr. Marcus Gossler (Own work) CC-BY-SA-3.0 (http://creativecommons.org/licenses/by-sa/3.0/)], via Wikimedia Commons

Was ist ein Imagekatalog?

N.Mus. 17 954 Morart, Wolfg. 7 Afmad. 7 Mozart, Wolfgang Amadeus Drei Gesånge m. Begl. d. Forte Piano's KV 39. W[olfgang] A[madeus] Mozart. Konzert Nr 2. B-dur. Rev. Ausg. mit Fingersatz u. Vortragszeichen... Braunschweig: Musikal Magazin a. d. Höhe. (Collection compl. No. 12.) von Carl Reinecke. (Solostimme.) Leipzig: Breitkopf & Härtel []. 15 S. 4° (Mozart: Sämtliche Klavier-Konzerte. 2.) (Hymne and Harmonie Roch 345. Abschiedolied: 89/Ar "Vergiss mein nicht" [Komp. Lor. Schneider].

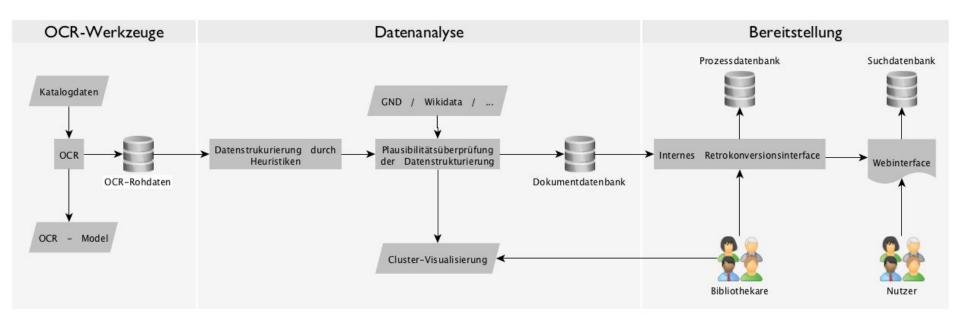
Phillip an das blavier [Komp. Lor. Schneider].)

Technische Umsetzung

Umsetzung bis jetzt:

- Planung von Open-Source Anwendung(en)
- Python-Skripte zur Datenverarbeitung
- Visualisierung/Interaktion/Bearbeitung erfolgt in der Webanwendung (Ruby-on-Rails)
- Dokumentation

Übersicht des gesamten Prozesses



Texterkennung

- Anpassung, Training (ML) und Evaluierung von OCR-Software
- Trainingsdaten finden und erstellen
- Bestehende Datensätze nutzen (z.B. Indexierung von einigen Karten)



Beispiel eines erkannten Text:

Reirnam Aribert: DasLSohloss [Forts.]

Informationsgewinnung

- Umsetzung im 2. Semester
- Entitäten (Autoren, Werke, ...) im Text erkennen.
- Informationen aus Datenbanken (GND, Wikidata, ...) verknüpfen

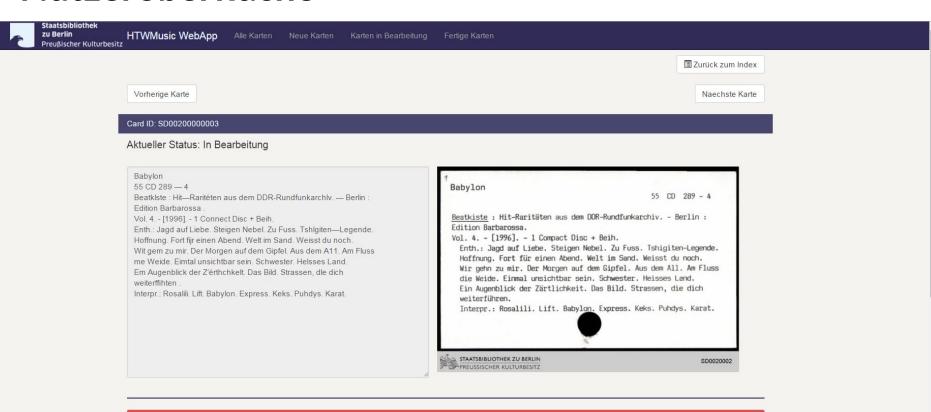
Reirnam Aribert: DasLSohloss [Forts.]



Nutzeroberfläche

- Darstellung der Ergebnisse
- Visualisiert den Stand der Retrokonversion
- Webservice mit Weboberfläche (HTML5, CSS und JS)
- Management der Retrokonversion

Nutzeroberfläche



Gelesener Text Korrektur Feld-Typ Status

Nutzeroberfläche

